

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
II	Aprendizaje Estadístico y Modelos de Clasificación	2
1.	Cap. 24: CBR en Sistemas Inteligentes	3
1.1.	Introducción	3
1.2.	Fundamentos Teóricos	3
1.2.1.	Definición y Naturaleza del Paradigma	3
1.2.2.	Los Contenedores de Conocimiento	4
1.2.3.	El Ciclo de las 4R y 5R	4
1.3.	Metodología y Análisis de la Literatura	4
1.3.1.	Arquitecturas Avanzadas en Sistemas Inteligentes	4
1.3.2.	Implementaciones Matemáticas del Razonamiento	5
1.3.3.	Áreas de Aplicación y Casos de Estudio	5
1.3.4.	Limitaciones y Desafíos Identificados	6
1.3.5.	Integración y Funcionalidad del CBR en Sistemas Inteligentes: Respuesta a la Pregunta de Investigación	6
1.3.6.	Comparación entre CBR y otras técnicas de Inteligencia Artificial y análisis	8
1.3.7.	Herramientas y Frameworks para el Desarrollo de Sistemas CBR Industriales	9
1.3.8.	Análisis Detallado de los Formalismos de Representación de Casos	9
1.3.9.	Taxonomía Funcional de la IA Explicable Basada en Casos (XCBR)	9
1.4.	Conclusiones	10

Parte I

Introducción y Fundamentos

Parte II

Aprendizaje Estadístico y Modelos de Clasificación

Capítulo 1

Modelado de Sistemas Inteligentes mediante el Enfoque de Razonamiento Basado en Casos (CBR)

Autor: Saavedra Jaramillo Daniel Alejandro (daniel.saavedra@unl.edu.ec)
Técnica asignada: Razonamiento basado en casos

1.1. Introducción

El modelado de sistemas inteligentes ha experimentado un cambio de paradigma, evolucionando desde la rigidez de los sistemas basados en reglas hacia modelos capaces de aprender de la experiencia previa. El Razonamiento Basado en Casos (Case-Based Reasoning, CBR) se erige como una metodología fundamental en la Inteligencia Artificial (IA) contemporánea, fundamentada en la premisa cognitiva de que situaciones similares suelen tener soluciones similares. A diferencia de los modelos de aprendizaje automático tradicionales que requieren miles de ejemplos para generalizar, el CBR permite la resolución de problemas en dominios donde la teoría es débil o el conocimiento está fragmentado, pero la experiencia episódica es abundante. [1–4]

La importancia del CBR radica en su capacidad para ofrecer un aprendizaje incremental y natural, donde cada nuevo problema resuelto se convierte en conocimiento útil para el futuro. Este informe aborda la pregunta de investigación: “¿Cómo se utiliza el razonamiento basado en casos en sistemas inteligentes?”. Para ello, se analizan arquitecturas de vanguardia como los Sistemas Gemelos (Twin Systems) para la IA explicable, el CBR Federado (F-CBR) para entornos distribuidos y la arquitectura EXAR para razonamiento agéntico integrado con modelos de lenguaje. El documento se estructura en secciones que detallan los fundamentos teóricos, la formalización matemática de sus procesos y un análisis crítico de la literatura aplicada en sectores como la medicina, la defensa y la gestión energética. [1, 2, 5–7]

1.2. Fundamentos Teóricos

1.2.1. Definición y Naturaleza del Paradigma

El CBR no se define simplemente como una tecnología, sino como una metodología de resolución de problemas que emula el razonamiento analógico humano. El origen del CBR se remonta a finales de la década de 1970 con los trabajos de Roger Schank en la Universidad de Yale sobre la memoria dinámica y el papel de la memoria episódica en el aprendizaje humano. Evolucio-

nó desde un modelo puramente cognitivo hacia una metodología robusta de IA, impulsada por sistemas pioneros como CYRUS y marcos de desarrollo como jCOLIBRI. En 1999, Watson formalizó una distinción crítica: el CBR es una metodología, no una tecnología específica, lo que le permite integrarse con técnicas como lógica difusa, redes neuronales y bases de datos SQL. Es un enfoque de aprendizaje perezoso (*lazy learning*), ya que no construye un modelo general del dominio a priori, sino que espera a que surja un problema para recuperar la información relevante. [4, 5, 8–10]

1.2.2. Los Contenedores de Conocimiento

Un sistema inteligente basado en CBR organiza su saber en cuatro contenedores críticos que permiten su funcionamiento [3, 6, 9]:

1. **Vocabulario:** Define los términos y atributos para describir los casos.
2. **Medida de Similitud:** El conocimiento sobre qué características hacen que dos problemas sean comparables.
3. **Conocimiento de Adaptación:** Reglas o métodos para ajustar una solución antigua a un contexto nuevo.
4. **Base de Casos:** El repositorio de experiencias previas, estructurado típicamente como una tríada de descripción del problema, solución y resultado (*outcome*).

1.2.3. El Ciclo de las 4R y 5R

El modelado funcional del CBR se rige por un proceso cíclico formalizado por Aamodt y Plaza [1, 2, 4, 5, 8, 10, 11]:

- **Recuperar (Retrieve):** Dado un problema nuevo, el sistema busca en la base de casos aquellos más similares utilizando algoritmos como k-NN.
- **Reutilizar (Reuse):** Se propone la solución del caso recuperado para el nuevo problema.
- **Revisar (Revise):** La solución se evalúa en el mundo real. Si falla, se ajusta o repara basándose en la retroalimentación del experto.
- **Retener (Retain):** La experiencia consolidada (éxito o fracaso) se almacena, permitiendo que el sistema "crezca" intelectualmente.

Algunos modelos modernos añaden la fase de Representación como una fase inicial (modelo 5R) para formalizar el caso antes del ciclo.

1.3. Metodología y Análisis de la Literatura

1.3.1. Arquitecturas Avanzadas en Sistemas Inteligentes

La literatura actual muestra que el CBR ya no opera de forma aislada, sino que es el eje integrador de sistemas complejos:

Sistemas Gemelos para la IA Explicable (XCBR)

Una de las aplicaciones más potentes es el uso del CBR para dotar de transparencia a modelos de "caja negra" como las Redes Neuronales Artificiales (ANN). En esta arquitectura, la ANN realiza la predicción de alta precisión, mientras que el módulo CBR actúa como un sistema de "caja blanca" que proporciona explicaciones por ejemplo. El sistema recupera casos reales que justifican por qué el modelo tomó una decisión, aumentando la confianza del usuario. [1, 8]

CBR Federado (F-CBR) y Privacidad

Para sistemas inteligentes distribuidos (como hospitales que no pueden compartir datos de pacientes), el F-CBR propone una arquitectura donde múltiples sistemas colaboran sin centralizar los datos. Utiliza un proceso de recuperación en dos etapas: los miembros envían puntuaciones de similitud anónimas a un "federado" y solo se comparten los casos específicos que superan un umbral de relevancia, garantizando la privacidad de la información sensible. [7]

Razonamiento Agéntico y EXAR

La arquitectura EXAR introduce una visión de agentes especializados que orquestan el razonamiento. A diferencia del ciclo secuencial tradicional, agentes de análisis, recuperación y optimización trabajan sobre una memoria a corto plazo, permitiendo integrar el CBR con Modelos de Lenguaje de Gran Escala (LLM) a través de técnicas como RAG (Generación Aumentada por Recuperación) para mitigar alucinaciones y proveer contexto basado en experiencias reales. [6]

1.3.2. Implementaciones Matemáticas del Razonamiento

El CBR inteligente requiere una base matemática sólida para cuantificar la similitud entre casos [1, 8, 9, 12–14]:

- **Fórmula k-NN Ponderada:** Se utiliza para calcular la similitud global (Sim) sumando las similitudes locales de cada atributo (sim_i) multiplicadas por su peso (w_i):

$$Similarity(T, S) = \frac{\sum_{i=1}^n w_i \times sim(f_{Ti}, f_{Si})}{\sum_{i=1}^n w_i} \quad (1.1)$$

- **Métricas de Incertidumbre:** Investigaciones recientes utilizan la **distancia de Wasserstein** para comparar atributos representados como números difusos triangulares, lo que permite al sistema manejar datos imprecisos en entornos de alta incertidumbre.
- **Optimización de Pesos:** Se emplean técnicas como el **peso de entropía** o el uso de **Máquinas de Vectores de Soporte (SVM)** para aprender automáticamente qué atributos son más importantes para la toma de decisiones.

1.3.3. Áreas de Aplicación y Casos de Estudio

Medicina y Salud Digital

Es el área con mayor madurez. Sistemas como **RESPIDIAG** para enfermedades pulmonares y modelos para el diagnóstico de **diabetes mellitus** han demostrado que el CBR es ideal para el apoyo a la decisión clínica. Un estudio destacado en **Colombia** aplicó un sistema gemelo NN-CBR para predecir el riesgo de enfermedad renal crónica con un 95 % de precisión, generando explicaciones automáticas en lenguaje natural sobre por qué un paciente específico estaba en riesgo basándose en diagnósticos previos similares. [8, 15]

Defensa y Gestión de Crisis

En el ámbito militar, el CBR se utiliza para generar planes de ataque de fuego conjunto y estrategias para enjambres de drones (UAV). En estos casos, la velocidad es crítica; el sistema extrae características contextuales (clima, número de objetivos, tiempo límite) y recomienda misiones pasadas exitosas, superando en eficiencia a las búsquedas por palabras clave tradicionales. [12, 13]

Educación y Gestión Energética

- **Sistemas de Tutoría Inteligente (ITS):** El sistema **CRISTAL** utiliza CBR para personalizar el aprendizaje de álgebra, adaptando el material educativo según el perfil de conocimiento previo y el estilo de aprendizaje del estudiante [16].
- **Edificios Inteligentes:** Se han desarrollado agentes de software que utilizan CBR para recomendar reducciones de energía en tiempo real, validando las sugerencias mediante reglas de expertos en la fase de revisión. [1, 14]

1.3.4. Limitaciones y Desafíos Identificados

A pesar de sus beneficios, la literatura reporta obstáculos significativos:

- **CBM (Mantenimiento de la Base de Casos):** El crecimiento masivo de datos puede degradar el rendimiento. Es necesario implementar estrategias de limpieza para eliminar casos redundantes o ruidosos. [3, 10]
- **Cuello de botella en la Adaptación:** La fase de reutilización/adaptación sigue siendo la más difícil de automatizar. Muchos sistemas actuales dependen de una adaptación manual o de reglas muy rígidas, lo que limita su flexibilidad. [3, 4]
- **Ingeniería del Conocimiento:** Construir ontologías sólidas (como CBROnto) para que el sistema "entienda" semánticamente los casos es un proceso costoso y complejo. [5, 15, 17]

1.3.5. Integración y Funcionalidad del CBR en Sistemas Inteligentes: Respuesta a la Pregunta de Investigación

Para responder de forma concluyente a la pregunta: "¿Cómo se utiliza el razonamiento basado en casos en sistemas inteligentes?", es necesario analizar el CBR no solo como un algoritmo, sino como un componente de orquestación de conocimiento que interactúa con diversas arquitecturas de IA. La literatura científica actual describe su uso a través de los siguientes mecanismos de integración:

Como Capa de Explicabilidad en Sistemas Gemelos (IA Híbrida)

Uno de los usos más críticos en la actualidad es la creación de sistemas gemelos (twin systems), donde el CBR se utiliza para dotar de transparencia a modelos predictivos opacos, como las redes neuronales artificiales (ANN) o el aprendizaje profundo (DL). [1, 5]

- **Mecanismo de funcionamiento:** Mientras que la red neuronal realiza una predicción de alta precisión (por ejemplo, el riesgo de una enfermedad o el precio de una vivienda), el sistema CBR extrae los pesos de las características (feature-weights) calculados por el modelo de "caja negra". [1, 8]
- **Justificación por ejemplo:** El CBR utiliza esos pesos para realizar una recuperación de vecinos cercanos en la base de casos y presentar al usuario humano ejemplos reales que comparten similitudes estadísticas y clínicas con el caso actual. Así, el sistema no solo entrega un resultado numérico, sino una explicación en lenguaje natural basada en precedentes: "Este paciente tiene riesgo alto porque es similar a estos tres casos pasados que compartían edad e hipertensión". [6]

Como Memoria Persistente para Modelos de Lenguaje (EXAR)

En la frontera de la IA, el CBR se utiliza para mitigar las debilidades de los **Modelos de Lenguaje de Gran Escala (LLMs)**, como las alucinaciones y la falta de memoria a largo plazo, mediante la arquitectura EXAR. [6]

- **Generación Aumentada por Recuperación (RAG):** El CBR actúa como una estructura de memoria externa que proporciona contextos de alta calidad. En lugar de una recuperación semántica simple, utiliza el ciclo 4R para identificar **trazas de razonamiento pasadas** que guían al LLM en la generación de respuestas alineadas con la experiencia probada del sistema. [6]
- **Adaptación Agéntica:** Los sistemas inteligentes modernos emplean agentes especializados (Análisis, Recuperación, Adaptación) que coordinan sus acciones sobre una memoria a corto plazo (STM), permitiendo que el razonamiento no sea solo secuencial, sino dinámico y capaz de manejar problemas abiertos. [6]

Como Infraestructura de Aprendizaje Colaborativo y Privado (F-CBR)

En dominios donde la privacidad de los datos es mandatoria (como la medicina o la banca), el CBR se utiliza para construir **redes federadas**.

- **Colaboración sin centralización:** El sistema inteligente se despliega de forma distribuida; cada institución mantiene su propia base de casos de forma autónoma. Cuando surge un problema nuevo, se realiza una recuperación en dos etapas: los nodos locales calculan puntuaciones de similitud y solo el "federador" recibe los metadatos necesarios para identificar el mejor caso global, cumpliendo con principios de minimización de datos como los del GDPR. [7]

Como Motor de Personalización en Sistemas de Tutoría y Recomendación

El CBR permite que los sistemas inteligentes adapten su comportamiento a las características individuales del usuario. [16]

- **Modelado del usuario:** En sistemas como CRISTAL, el CBR almacena perfiles de aprendizaje de estudiantes previos (estilo de aprendizaje, conocimiento previo, resultados). Al enfrentar a un nuevo estudiante, el sistema recupera la "experiencia" de alumnos similares para personalizar el material educativo y la estrategia de enseñanza en tiempo real. [16]
- **Sistemas de recomendación semántica:** Mediante el uso de ontologías (como CBROn-to o iSeeOnto), el CBR permite que el sistema "entienda" las relaciones entre conceptos, ofreciendo recomendaciones que no solo son estadísticamente similares, sino semánticamente relevantes para el contexto del usuario. [3, 5]

1.3.6. Comparación entre CBR y otras técnicas de Inteligencia Artificial y análisis

Técnica	Fundamento Teórico / Enfoque	Principales Ventajas	Limitaciones Clave	Ejemplos de Aplicación
CBR (Razonamiento Basado en Casos)	Razonamiento analógico y experiencial. “Problemas similares tienen soluciones similares”. [5, 15]	Aprendizaje incremental; no requiere un modelo teórico profundo; ofrece explicabilidad natural mediante ejemplos. [5, 15]	Costo computacional en bases masivas; dificultad para automatizar la fase de adaptación. [5, 15]	Diagnóstico de diabetes; estrategias para enjambres de drones; tutoría en álgebra (CRISTAL). [5, 15]
RBR (Razonamiento Basado en Reglas)	Modelado explícito del dominio mediante estructuras rígidas tipo “si-entonces” (<i>if-then</i>). [10]	Eficaz en dominios con leyes formales y teorías sólidas bien definidas. [10]	Cuello de botella en la adquisición de conocimiento; rigidez ante cambios; difícil mantenimiento. [10]	Sistema MYCIN para diagnóstico de infecciones bacterianas. [10]
ANN (Redes Neuronales Artificiales)	Modelos matemáticos de aprendizaje profundo basados en pesos y funciones de activación. [8]	Alta precisión en el reconocimiento de patrones complejos y datos masivos. [8]	Naturaleza de “caja negra” (opacidad); requiere grandes volúmenes de datos etiquetados para entrenamiento.	Predicción de riesgo de Enfermedad Renal Crónica en Colombia. [8]
FCM (Mapas Cognitivos Difusos)	Grafos causales ponderados que modelan influencias entre conceptos del dominio. [15]	Permite modelar relaciones cualitativas y lingüísticas imprecisas (“bajo”, “medio”, “alto”). [15]	Muy dependiente de la pericia del experto para definir pesos iniciales; sensible a la configuración del grafo. [15]	Tratamiento de infecciones del tracto urinario no complicadas. [15]
Búsqueda en Bases de Datos (SQL)	Recuperación de información basada en coincidencias exactas o operadores lógicos. [18]	Alta velocidad de respuesta; seguridad de datos y estándares de integridad robustos. [18]	Limitada a coincidencias exactas; no mide similitud semántica sin capas de conocimiento adicionales. [18]	Sistema SQUAD de control de calidad de software en NEC. [18]
Data Mining (Minería de Datos)	Extracción de patrones ocultos y conocimiento general en grandes depósitos de datos. [2]	Capacidad para descubrir conocimiento nuevo y leyes generales no evidentes. [2]	Se enfoca en la generalización (<i>eager learning</i>); a menudo carece del componente de resolución de problemas específicos. [2]	Descubrimiento de biomarcadores en datos de microarrays de ADN. [2]

1.3.7. Herramientas y Frameworks para el Desarrollo de Sistemas CBR Industriales

La implementación de sistemas inteligentes basados en CBR se ha visto potenciada por el desarrollo de frameworks de "espectro amplio" como jCOLIBRI. Esta plataforma, basada en Java y orientada a objetos, ejemplifica cómo se orquesta el razonamiento en la práctica. [5]

Separación de Métodos y Modelos de Dominio

Una de las contribuciones clave de jCOLIBRI es la separación entre los **Métodos de Resolución de Problemas (PSM)**, que definen los procesos de razonamiento, y el **Modelo de Dominio**, que describe el conocimiento específico. Esta arquitectura permite la reutilización de diseños previos y facilita el prototipado rápido mediante una interfaz gráfica que guía al diseñador sin necesidad de escribir código directamente. [5]

Ontologías y Gestión de Persistencia

El framework utiliza una ontología independiente del dominio llamada CBROnto para formalizar el conocimiento del CBR. Para la gestión de datos masivos, introduce el concepto de "Connectors", objetos que abstraen el acceso a bases de datos relacionales, archivos XML o sistemas de lógica descriptiva, devolviendo los casos al sistema de forma uniforme. Además, distingue entre el pre-ciclo (indexación y preparación de datos), el ciclo principal de las 4R y el post-ciclo (mantenimiento y eliminación de casos no útiles). [5]

1.3.8. Análisis Detallado de los Formalismos de Representación de Casos

La literatura subraya que la eficiencia de un sistema inteligente CBR depende críticamente de cómo se estructura la unidad de conocimiento. Dependiendo de la complejidad del dominio, se utilizan diversos formalismos [4, 19, 20]:

- **Vectores de Características:** Es el método más común, donde el caso se representa como pares atributo-valor, ideal para diagnósticos médicos simples.
- **Representación por Marcos (Frames):** Estructura el conocimiento en "ranuras" (slots) y "facetras", permitiendo manejar restricciones y condiciones, aunque con una eficiencia de razonamiento menor en comparación con los vectores.
- **Orientación a Objetos:** Utiliza jerarquías de clases para representar casos complejos donde los atributos están interconectados, facilitando el manejo de datos heterogéneos.
- **Redes Semánticas:** Representa casos como nodos y arcos que definen relaciones ("es-un", "tiene-un"). Es altamente flexible pero puede presentar rigidez en procesos de razonamiento a gran escala.
- **Grafos de Conocimiento:** Tendencia actual que integra CBR con tecnologías de la Web Semántica (RDF/OWL) para permitir razonamiento descriptivo profundo.

1.3.9. Taxonomía Funcional de la IA Explicable Basada en Casos (XCBR)

El uso del CBR como motor de explicabilidad en sistemas inteligentes se organiza en siete dimensiones funcionales que deben ser atendidas para generar confianza en él [3]:

1. **Interpretación Semántica:** Capacidad de generar explicaciones conceptualmente significativas alineadas con el entendimiento del usuario.

2. **Explicaciones Intuitivas:** Uso de razonamiento analógico o contrastivo ("¿por qué no X en lugar de Y?") para facilitar la comprensión.
3. **Precisión y Relevancia Continua:** Garantía de que las explicaciones evolucionan a medida que cambian los datos de entrada o el contexto del usuario
4. **Refinamiento de Explicaciones:** Soporte para la mejora iterativa del sistema mediante la retroalimentación directa del experto humano
5. **Eficiencia de Recursos:** Capacidad de escalar el mecanismo de explicación sin disparar los costos computacionales o de almacenamiento
6. **Calidad de la Evaluación:** Uso de métricas multidimensionales para medir la utilidad y la fiabilidad de la explicación generada
7. **Transparencia de Proceso (Trace-based):** Documentación de la secuencia de pasos que el sistema tomó para llegar a la conclusión

1.4. Conclusiones

La investigación permite concluir que el razonamiento basado en casos no es solo un componente de búsqueda, sino una metodología de orquestación del conocimiento experiencial que dota a los sistemas inteligentes de capacidades de aprendizaje continuo y explicabilidad. Respondiendo a la pregunta de investigación, el CBR se utiliza en sistemas inteligentes de tres maneras principales:

1. Como un intérprete de modelos opacos, transformando predicciones matemáticas en justificaciones basadas en ejemplos humanos.
2. Como un mecanismo de colaboración distribuida, permitiendo el aprendizaje colectivo sin violar la privacidad de los datos.
3. Como un motor de personalización dinámica, adaptando contenidos educativos o planes estratégicos a las particularidades del contexto actual.

Los hallazgos subrayan que la tendencia futura se dirige hacia el Deep CBR y la integración con LLMs, donde el aprendizaje profundo automatizará la extracción de características y los modelos de lenguaje facilitarán una adaptación más fluida de las soluciones. El CBR reafirma que la experiencia es un activo tan crítico como el algoritmo, consolidándose como la columna vertebral de una Inteligencia Artificial más humana, transparente y adaptable.

Referencias

- [1] M. T. Keane and E. M. Kenny, “How case-based reasoning explains neural networks: A theoretical analysis of xai using post-hoc explanation-by-example from a survey of ann-cbr twin-systems,” tech. rep., 8 2019.
- [2] I. Bichindaritz and C. Marling, “Case-based reasoning in the health sciences: Foundations and research directions,” tech. rep., 5 2010.
- [3] P. Pradeep, M. Caro-Martínez, and A. Wijekoon, “Empowering explainable artificial intelligence through case-based reasoning: A comprehensive exploration,” 12 2025.
- [4] A. Yan and Z. Cheng, “A review of the development and future challenges of case-based reasoning,” 8 2024.
- [5] B. Díaz-Agudo, P. A. González-Calero, J. A. Recio-García, and A. A. Sánchez-Ruiz-Granados, “Building cbr systems with jcolibri,” *Science of Computer Programming*, vol. 69, pp. 68–75, 12 2007.
- [6] R. Bergmann, F. Brand, M. Lenz, and L. Malburg, “Exar: A unified experience-grounded agentic reasoning architecture,” in *Lecture Notes in Computer Science*, vol. 15662 LNAI, pp. 1–15, Springer Science and Business Media Deutschland GmbH, 6 2025.
- [7] A. Jaiswal, K. Y. Yigzaw, and P. Ozturk, “F-cbr: An architecture for federated case-based reasoning,” *IEEE Access*, vol. 10, pp. 75458–75471, 7 2022.
- [8] G. R. Vasquez-Morales, S. M. Martinez-Monterrubio, P. Moreno-Ger, and J. A. Recio-Garcia, “Explainable prediction of chronic renal disease in the colombian population using neural networks and case-based reasoning,” *IEEE Access*, vol. 7, pp. 152900–152910, 10 2019.
- [9] K. W. Huang and C. H. Wang, “Constructing the intelligence headache diagnosis model by cbr,” in *ACM International Conference Proceeding Series*, pp. 32–35, Association for Computing Machinery, 12 2021.
- [10] S. K. Biswas, N. Sinha, and B. Purkayastha, “A review on fundamentals of case-based reasoning and its recent application in different domains nidul sinha ’a review on fundamentals of case-based reasoning and its recent application in different domains,” tech. rep., 2014.
- [11] Y. Asim, B. Raza, A. K. Malik, A. R. Shahaid, and H. Alquhayz, “An adaptive model for identification of influential bloggers based on case-based reasoning using random forest,” *IEEE Access*, vol. 7, pp. 87732–87749, 7 2019.
- [12] X. Jin, X. Wang, F. Cai, and Y. Guo, “Cbr and focus learning based joint fire strike plan generation method,” in *ACM International Conference Proceeding Series*, pp. 210–217, Association for Computing Machinery, 8 2022.

- [13] M. Huang, T. Wang, T. Jing, S. Yang, X. Zhou, and H. He, “Case-based reasoning of operation strategies recommendation for uav swarm,” *Journal of Systems Engineering and Electronics*, vol. 36, pp. 1548–1561, 12 2025.
- [14] T. Pinto, R. Faia, M. Navarro-Caceres, G. Santos, J. M. Corchado, and Z. Vale, “Multi-agent-based cbr recommender system for intelligent energy management in buildings,” *IEEE Systems Journal*, vol. 13, pp. 1084–1095, 3 2019.
- [15] S. El-Sappagh and M. M. Elmogy, “Medical case based reasoning frameworks: Current developments and future directions,” *International Journal of Decision Support System Technology*, vol. 8, pp. 31–62, 7 2016.
- [16] M. Masood and N. A. M. Mokmin, “Case-based reasoning intelligent tutoring system: An application of big data and iot,” in *ACM International Conference Proceeding Series*, vol. Part F132530, pp. 28–32, Association for Computing Machinery, 10 2017.
- [17] D. Wu, J. Chen, R. Xie, and K. Chen, “Ontocsd: an ontology-based security model for an integrated solution of cyberspace defense,” *Frontiers of Information Technology and Electronic Engineering*, vol. 25, pp. 1209–1225, 9 2024.
- [18] I. Watson, “Case-based reasoning is a methodology not a technology,” tech. rep., 3 1999.
- [19] M. Asif and J. Ahmed, “A novel case base reasoning and frequent pattern based decision support system for mitigating software risk factors,” *IEEE Access*, vol. 8, pp. 102278–102291, 6 2020.
- [20] N. A. Butt, Z. Mahmood, G. U. Rehman, M. M. Nasralla, M. Zubair, H. Farman, and S. B. A. Khattak, “The development of intelligent agents: A case-based reasoning approach to achieve human-like peculiarities via playback of human traces,” *IEEE Access*, vol. 11, pp. 78693–78712, 6 2023.